

Modelowanie i identyfikacja – laboratorium 4.

Dystrybuanta empiryczna i jej własności

Paweł Wachel

Wymagania wstępne:

1. Wymagania wstępne z poprzednich zajęć¹.
2. Znajomość konstrukcji estymatora dystrybuanty empirycznej.
3. Pojęcie obciążenia i wariancji estymatora – definicja i interpretacja.

Zadania do wykonania:

1. Wykorzystując opracowane na wcześniejszych zajęciach generatory, wygenerować N -elementowy ciąg liczb losowych $\{X_1, X_2, \dots, X_N\}$ o gęstości prawdopodobieństwa:

$$f(x) = \begin{cases} 2x & \text{dla } x \in [0, 1] \\ 0 & \text{dla } x \in (-\infty, 0) \cup (1, \infty) \end{cases}.$$

2. Wykreślić dystrybuantę powyższego rozkładu (oznaczaną dalej przez $F(x)$), zaimplementować i wykreślić dystrybuantę empiryczną:

$$\hat{F}_N(x) = \frac{1}{N} \sum_{n=1}^N \mathbf{I}(X_n \leq x),$$

gdzie $\mathbf{I}(a \leq b) = 1$, gdy $a \leq b$ i 0 w przeciwnym przypadku.

3. Zaimplementować empiryczny odpowiednik wyrażenia

$$D_N = \sup_x \left| \hat{F}_N(x) - F(x) \right|$$

i wykreślić realizację D_N w funkcji N . Zinterpretować uzyskane rezultaty.

4. Plik `ModelowanieLab4Data.txt` zawiera pewną sekwencję pomiarów. Wykreślić dystrybuantę empiryczną $\hat{F}_N(x)$ dla różnych wartości N . Z jakiego rozkładu pochodzą dane²? Rozważyć rozkłady: normalny³ $\mathcal{N}(1, 1)$, normalny $\mathcal{N}(0, 5)$ oraz Cauchy’ego z parametrami $x_0 = 0$ i $\gamma = 1$?
5. Skonstruować eksperyment symulacyjny, umożliwiający estymację wariancji dystrybuanty empirycznej ($\sigma_F^2(x) = \text{Var}\{\hat{F}_N(x)\}$). Wykreślić wartość oszacowania wariancji $\hat{\sigma}_F^2(x)$ w funkcji x .

¹Całkujemy wiedzę... przynajmniej do wakacji.

²Można zaproponować własne kryterium ułatwiające określenie rozkładu lub skorzystać z wybranego testu statystycznego.

³Do pracy z dystrybuantą rozkładu normalnego można wykorzystać funkcję $\text{erf}(\mathbf{x})$.

Zadania dodatkowe:

1. Dla wybranego rozkładu prawdopodobieństwa wygenerować L niezależnych, N -elementowych sekwencji pomiarowych (prób) i wyznaczyć błąd empiryczny

$$Err \left\{ \hat{F}_N \right\} = \frac{1}{LM} \sum_{l=1}^L \sum_{m=1}^M \left[\hat{F}_N^{[l]}(x_m) - F(x_m) \right]^2,$$

w którym $\{x_1, x_2, \dots, x_M\}$ jest sekwencją równoodległych punktów z pewnego odcinka $[a, b]$, a $\hat{F}_N^{[l]}$ jest l -tą realizacją estymatora. Badania rozpocząć od $M = 100$ i $L = 10$. Jaki wpływ na uzyskiwane wyniki mają stałe L i M ?

2. Zaproponować eksperyment numeryczny obrazujący (punktową) zbieżność według rozkładu dystrybuanty empirycznej do rozkładu normalnego, tzn.

$$\sqrt{N} \left[\hat{F}_N(x) - F(x) \right] \xrightarrow{d} \mathcal{N}(0, F(x)(1 - F(x))),$$

dla dowolnego (ustalonego) $x \in \mathbb{R}$. Dokonać interpretacji uzyskanych wyników. W jaki sposób asymptotyczny rozkład normalny zależy od argumentu x ?

Literatura:

1. Wasserman, Larry. All of statistics: a concise course in statistical inference. Springer Science & Business Media, 2013.
2. Plucińska Agnieszka, Pluciński Edmund. Probabilistyka: rachunek prawdopodobieństwa, statystyka matematyczna, procesy stochastyczne. Wydawnictwa Naukowo-Techniczne, 2000.
3. Gajek Lesław, Kałuska Marek. Wnioskowanie statystyczne: modele i metody. Wydawnictwa Naukowo-Techniczne, 1993.
4. Notatki z wykładu.